

# ระบบประมาณราคารถยนต์มือสอง ด้วย Machine Learning

สรุปหมวด 1-4

# 1 การวางกรอบปัญหาและการวางแผน

- ปัญหา: ผู้ขายรถมือสองตั้งราคาไม่ถูก → ขาดทุน (ตั้งต่ำ) หรือขายช้า (ตั้งสูง)
- ML Task: Regression ทำนาย selling\_price (INR) จาก 12 features (ปี, เลขไมล์, ยี่ห้อ, เชื้อเพลิง ฯลฯ)
- ทำไมไม่ใช้ ML แทนกฎ: 30+ ยี่ห้อ × เชื้อเพลิง × เกียร์ × เจ้าของ เขียนกฎเองไม่ไหว; baseline ราคากลาง val MAPE 45.3% vs Ridge 17.1%
- Optimizing metric = MAE (อ่านเป็นเงินได้ตรง, ไม่ถูกรถหurdlingมากเท่า RMSE)
- Gating metric =  $\text{MAPE} \leq 20\%$  บน test set ( $\text{GATE\_MAPE} = 0.20$  ใน register.py)
- **[แทรกภาพ AI Project Canvas จาก Canva]**

# 1 เชื่อมตัวชี้วัดโมเดลกับธุรกิจ

| ตัวชี้วัด (test, champion v4) | ค่า                       | ความหมายเชิงธุรกิจ                            |
|-------------------------------|---------------------------|-----------------------------------------------|
| MAE                           | 177,922 INR (~69,400 THB) | 19.9% ของราคาเฉลี่ย 896,128 INR               |
| MAPE                          | 19.2%                     | ผ่าน gate $\leq 20\%$ (เหลือระยะห่าง 0.8 จุด) |
| คลาดไม่เกิน $\pm 20\%$        | 64.5% ของรถ               | ราคาแนะนำใช้งานได้                            |
| แมนที่สด: 700k–1.5M INR       | MAPE 14.8%                | ตลาดหลัก                                      |
| แย่งที่สด: < 300k INR         | MAPE 69.8%                | ควรแสดงคำเตือน                                |

แนะนำต่ำเกิน 20% = เสี่ยงขาดทุน (17.2%) · แนะนำสูงเกิน 20% = เสี่ยงขายช้า (18.3%)

## 2 ข้อมูลและการแบ่งชุด

- Kaggle CarDekho (Car details v3.csv) โหลดด้วย scripts/download\_data.py
- 8,128 แถว → 6,926 แถว หลังลบข้อมูลซ้ำ 1,202 แถว
- แบ่งตามปี ไม่สุ่ม: เทรนด้วยอดีต ทำนายอนาคต และ ทำซ้ำได้ ได้ชุดเดิมทุกครั้ง
- ข้อจำกัด: ข้อมูลอินเดีย (INR) สิ้นสุดปี 2020 ไม่มี ข้อมูลสภาพรถ

| ชุด   | เงื่อนไข       | จำนวน |
|-------|----------------|-------|
| train | ปี $\leq$ 2016 | 5,100 |
| val   | ปี 2017        | 808   |
| test  | ปี $\geq$ 2018 | 1,018 |

## 2 การตรวจสอบคุณภาพและป้องกัน Skew

- Pandera schema: ช่วงค่า, ค่าหมวดหมู่ที่อนุญาต, strict=True, lazy=True
- ข้อมูลเสียตอนเทรน → SchemaErrors → pipeline หยุด (exit 1) พิมพ์ FAILED at
- ดอนให้บริการ: API ดอน 422 (เช่น fuel="Water", year=2099, km\_driven=-5)
- unit test: ข้อมูลดี 1 เคสผ่าน, ข้อมูลเสีย 4 เคสถูกจับ
- clean\_cars() ตัวเดียวใช้ทั้ง train / API / monitor; imputer + scaler + one-hot ห่อใน Pipeline เดียวกัน export เป็น model.pkl
- คำหาย: median imputer; หมวดหมู่ไม่รู้จัก: OneHotEncoder(handle\_unknown="ignore")
- **[เพิ่มเหตุผลเรื่องค่าผิดปกติ (ไม่ clip/IQR) · แทรกคลิป์สาริตข้อมูลเสีย]**

### 3 เปรียบเทียบโมเดล

| โมเดล                    | val MAE        | val RMSE       | val MAPE     |
|--------------------------|----------------|----------------|--------------|
| baseline_median          | 415,937        | 734,079        | 45.3%        |
| <b>ridge (alpha=1.0)</b> | <b>120,615</b> | <b>187,566</b> | <b>17.1%</b> |
| hist_gbm                 | 129,150        | 356,127        | 14.4%        |
| random_forest            | 135,776        | 363,139        | 15.0%        |

- เลือก Ridge: MAE ต่ำสุด และ RMSE ต่ำกว่าโมเดลต้นไม้เกือบครึ่ง + เล็ก เร็ว อธิบายง่าย
- ข้อแลกเปลี่ยน: HistGBM/RF มี MAPE ดีกว่า แต่เลือกตาม MAE ที่ตั้งไว้ตั้งแต่ต้น
- ผล test: 184,906 / 19.6% → หลัง retrain (train + val) 177,922 / 19.2%

### 3 Hyperparameter Tuning และการอธิบายผล

| alpha              | val MAE        | test MAE       |
|--------------------|----------------|----------------|
| 0.1                | 121,908        | 182,880        |
| <b>1.0 (เลือก)</b> | <b>120,615</b> | <b>184,906</b> |
| 10                 | 124,064        | 192,207        |
| 50                 | 126,131        | 198,244        |
| 100                | 127,124        | 200,219        |

- ความสำคัญ: brand > year > fuel > max\_power
- year +1 SD (3.8 ปี) → ราคา +52.9%
- max\_power +1 SD (31 bhp) → +28.2%
- แบรินด์หรู (Land Rover, Mercedes, BMW) เป็นบวก; Tata, Chevrolet, Datsun เป็นลบ
- coefficient คือความสัมพันธ์ ไม่ใช่เหตุและผล

เลือกจาก val ไม่ใช่ test เพื่อกัน data leakage (ถ้าดู test จะได้ 0.1 ดีกว่า 2,026 แต่ไม่ทำ)

## 4 MLflow Experiment Tracking

| สิ่งที่บันทึก      | วิธี                                                         |
|--------------------|--------------------------------------------------------------|
| เวอร์ชันโค้ด       | param git_sha + tag mlflow.source.git.commit                 |
| เวอร์ชันข้อมูล     | data_version = MD5 ของ train.csv                             |
| ไฮเปอร์พารามิเตอร์ | mlflow.log_params(est.get_params())                          |
| ตัวชี้วัด          | val_mae, val_rmse, val_mape (+ test_mae, test_mape)          |
| ไฟล์ผลลัพธ์        | mlflow.sklearn.log_model พร้อม signature                     |
| สภาพแวดล้อม        | python / sklearn / pandas / numpy version + requirements.txt |

ตรวจด้วย mlflow.search\_runs() แล้ว: 4 run ล่าสุดมีครบทุกค่า [\[แทรกภาพหน้าจอ MLflow Compare\]](#)

## 4 Model Registry, Rollback และ Retrain

- Register: เลือก run MAE ต่ำสุด  $\rightarrow$  test  $\rightarrow$  promote เป็น champion เมื่อ  $MAPE \leq 20\%$  และ MAE ไม่แย่กว่า champion เดิม
- Rollback: ย้าย alias champion กลับเวอร์ชันที่มี gate\_passed=true (ทดสอบ: v3  $\rightarrow$  v1 โดยข้าม v2 ที่ตกด้าน)
- Retrain (train + val): challenger MAE 177,922 vs champion 184,906  $\rightarrow$  PROMOTE
- กรณี --alpha 1000: MAE 220,794 ผ่าน gate แต่แย่กว่า  $\rightarrow$  NOT PROMOTED
- ปัจจุบัน champion = version 4 (บันทึก ref\_mae 146,433 สำหรับ concept drift)